Used Car Price Prediction

Phase 1 Report Template

Data Exploration & Exploratory Data Analysis (EDA)

Task 1 – Load Dataset

آیا دیتاست با موفقیت بارگذاری شد؟

پاسخ:

بله، دیتاست بدون مشکل بارگذاری شد.

Task 2 – Initial Data Exploration

2-1. تعداد سطرها و ستون‌های دیتاست را بنویسید.

پاسخ:

دیتاست 4023 سطر (خودرو) و 12 ستون دارد.

2-2. نوع داده ستون‌ها را بررسی کنید.

به نظر شما:

- چند ستون عددی وجود دارد؟
- چند ستون متنی وجود دارد؟

پاسخ:
سه ستون عددی داریم: model_year، milage و price. بقیه یعنی 9 ستون متنی هستند: برند، مدل، نوع سوخت، موتور، گیربکس، رنگ بدنه، رنگ داخل، سابقه تصادف و وضعیت سند.

2-3. آیا دیتاست دارای مقدار گمشده (Missing Value) است؟

اگر بله، کدام ستون‌ها دارای مقدار گمشده هستند؟

پاسخ:

بله، دیتاست مقدار گمشده دارد. چهار ستون درگیر هستند: clean_title با 598 مورد (بیشترین)، fuel_type با 170 مورد، accident با 114 مورد و price با 28 مورد.

Task 3 – Data Preview

پس از مشاهده 5 سطر اول و 5 سطر آخر، ساختار کلی دیتاست را توضیح دهید.

مواردی که می‌توانید به آن اشاره کنید:

- نوع اطلاعات هر خودرو
- ستون هدف پروژه
- ستون‌های عددی
- ستون‌های متنی

پاسخ:
بعد از مشاهده 5 سطر اول و آخر مشخص شد هر خودرو با اطلاعاتی مثل برند، مدل، سال ساخت، کارکرد، نوع سوخت، موتور، گیربکس، رنگ بیرون و داخل، سابقه تصادف و وضعیت سند مشخص شده است. ستون هدف پروژه price است، یعنی همان چیزی که در فازهای بعدی قرار است پیش‌بینی شود. ستون‌های عددی (model_year، milage، price) کم‌تعدادند ولی مهم‌ترین‌ها هستند، و اکثر ستون‌های دیگر متنی و دسته‌ای هستند که توصیف ظاهری و وضعیت خودرو را نشان می‌دهند.

Task 4 – Statistical Analysis

نتایج تحلیل آماری را بررسی کنید.

میانگین قیمت خودروها:

پاسخ:
حدود 40326 دلار

میانگین میزان کارکرد خودروها:

پاسخ:

حدود 64664 مایل

قدیمی‌ترین سال ساخت:

پاسخ:

1974

جدیدترین سال ساخت:

پاسخ:

2024

آیا مقدار میانگین قیمت و کارکرد منطقی به نظر می‌رسد؟ دلیل خود را بنویسید.

پاسخ:
بله، منطقی است. با توجه به این‌که دیتاست هم خودروهای خیلی قدیمی (1974) و هم خودروهای صفر کیلومتر (2024) را در خود دارد، طبیعی است که میانگین کارکرد بالا (حدود 65 هزار مایل) باشد، چون خیلی از خودروها چند سالی استفاده شده‌اند. میانگین قیمت هم با توجه به تنوع دیتاست (از خودروی ارزان تا خودروی لوکس) قابل قبول است؛ فقط باید در نظر داشت که چون میانگین (40326) از میانه (31000) بیشتر است، چند خودروی خیلی گران‌قیمت این عدد را کمی بالا کشیده‌اند، پس میانگین به‌تنهایی نماینده دقیق اکثر داده‌ها نیست.

Task 5 – Feature Understanding

سوال 1

کدام برند بیشترین تعداد خودرو را دارد؟

پاسخ:

برند فورد با 387 خودرو

سوال 2

چند برند مختلف در دیتاست وجود دارد؟

پاسخ:

57 برند مختلف

سوال 3

کدام نوع سوخت بیشترین تعداد را دارد؟

پاسخ:
بنزینی (Gasoline) با 3321 خودرو، بیشترین تعداد را در بین انواع سوخت دارد.

سوال 4

قدیمی‌ترین و جدیدترین سال ساخت خودروها چیست؟

پاسخ:

قدیمی‌ترین سال 1974 و جدیدترین سال 2024

سوال 5

میانگین قیمت خودروها چقدر است؟

پاسخ:

حدود 40326 دلار

سوال 6

میانگین میزان کارکرد خودروها چقدر است؟

پاسخ:

حدود 64664 مایل

سوال 7

با توجه به اطلاعات این بخش، مهم‌ترین ویژگی‌های مؤثر بر قیمت خودرو از نظر شما کدام ستون‌ها هستند؟ دلیل خود را بنویسید.

پاسخ:

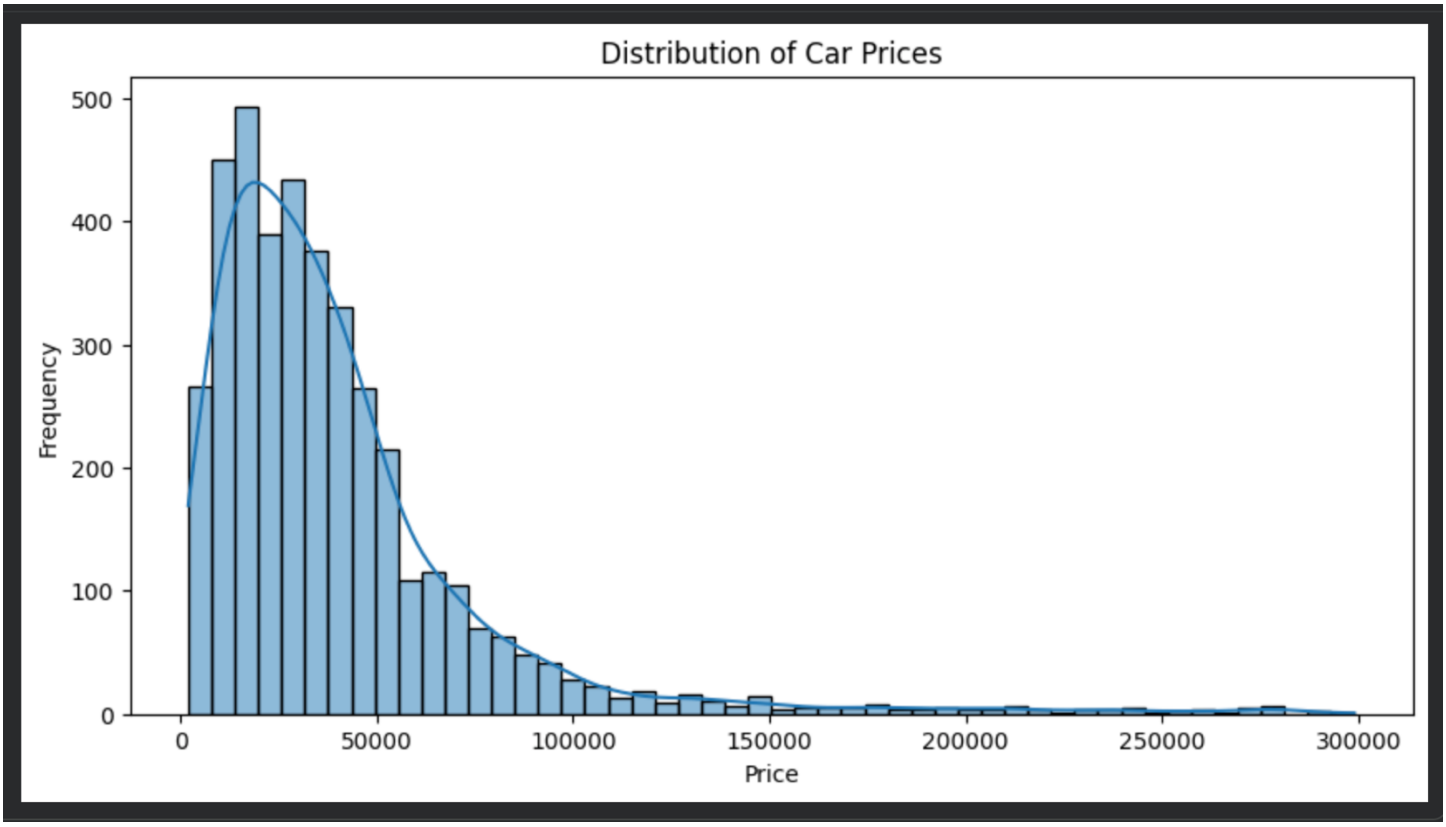
با توجه به تحلیل‌هایی که انجام شد، سه ستون بیشترین تأثیر را روی قیمت دارند: سال ساخت، چون رابطه مثبت و پیوسته‌ای با قیمت دارد و هرچه جدیدتر باشد گران‌تر است؛ کارکرد، چون رابطه معکوس واضحی با قیمت دارد و هرچه کارکرد بیشتر باشد قیمت پایین‌تر است؛ و برند، چون برندهای لوکس مانند پورشه یا مرسدس بنز طبیعتاً قیمت پایه بالاتری نسبت به برندهایی مانند هیوندای یا کیا دارند. این سه ستون هم از نظر منطقی و هم بر اساس نمودارهایی که رسم شد، بیشترین ارتباط را با قیمت نشان دادند.

Task 6 – Visualization & Data Analysis

نمودار اول

Price Distribution

تصویر نمودار را در این قسمت قرار دهید.



تحلیل نمودار

- آیا توزیع قیمت نرمال است؟
- آیا داده پرت مشاهده می‌شود؟
- نتیجه‌گیری شما چیست؟

:پاسخ
بیشترین تراکم داده در بازه 10000 تا 40000 دلار .(right-skewed) توزیع قیمت نرمال نیست و به سمت راست کشیده شده است قرار دارد و بعد از آن فرکانس به سرعت افت می‌کند. این موضوع با مشاهده قبلی که میانگین (40326) بیشتر از میانه (31000) بود .کاملاً همخوانی دارد

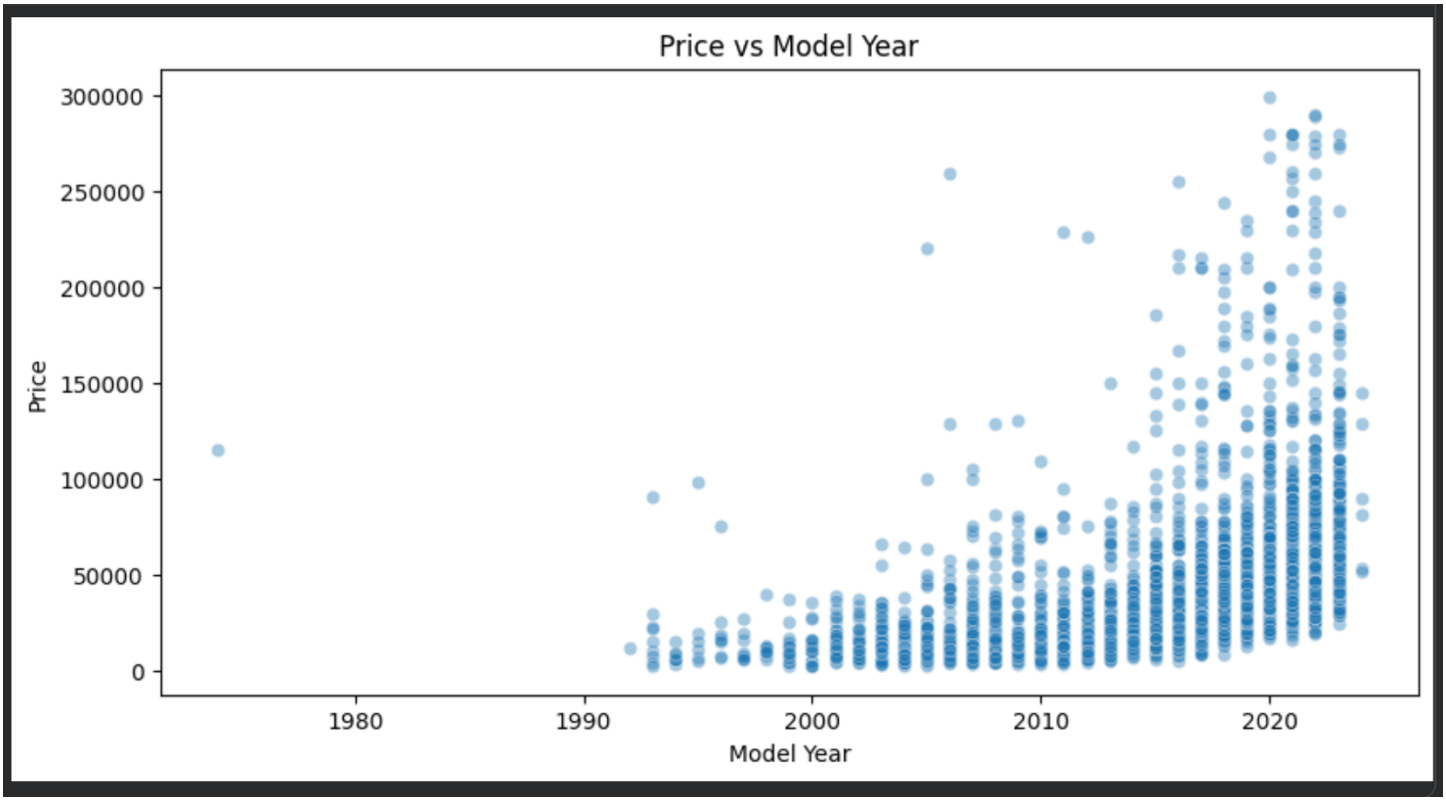
بله، داده پرت مشاهده می‌شود. یک دنباله بلند و کشیده تا حدود 300000 دلار در نمودار وجود دارد که نشان‌دهنده تعداد کمی خودروی .بسیار گران‌قیمت است. این خودروها در مقایسه با بقیه داده تراکم بسیار پایینی دارند

نتیجه‌گیری من این است که اکثر خودروهای این دیتاست در بازه قیمتی متوسط و پایین قرار دارند و تعداد کمی خودروی لوکس باعث کشیده شدن توزیع به سمت راست شده‌اند. به همین دلیل قبل از مدل‌سازی باید به این outlierها توجه ویژه‌ای شود.

نمودار دوم

Relationship between Model Year and Price

تصویر نمودار را در این قسمت قرار دهید.



تحلیل نمودار

- آیا خودروهای جدیدتر قیمت بیشتری دارند؟
- آیا رابطه واضح است؟

پاسخ:

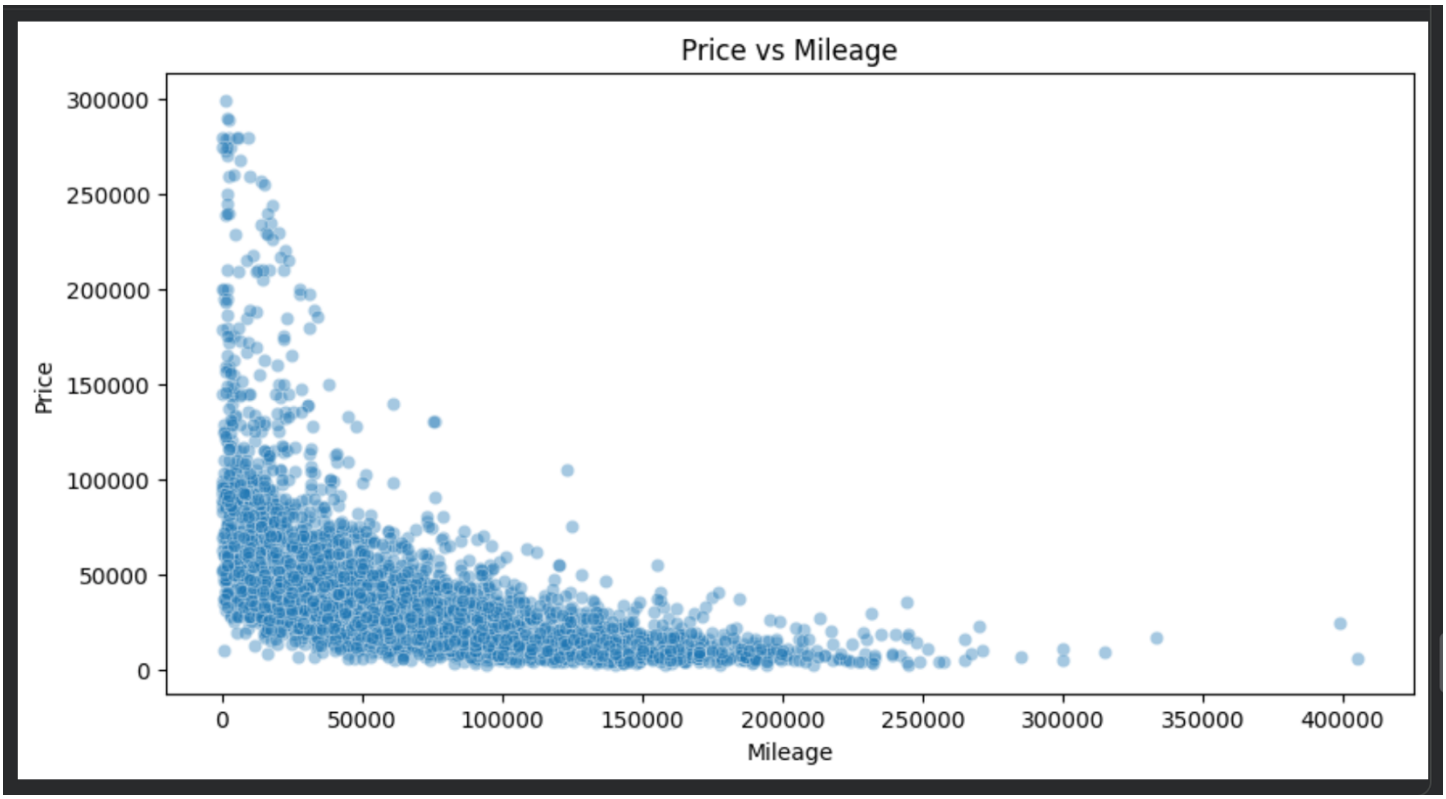
بله، خودروهای جدیدتر به طور کلی قیمت بیشتری دارند. با نزدیک شدن به سال‌های اخیر، به خصوص بعد از سال 2000، هم پراکندگی و هم بیشینه قیمت‌ها به طور محسوسی افزایش می‌یابد. برای خودروهای قبل از سال 1990 تقریباً هیچ داده‌ای نداریم و تنها یک نقطه در حدود سال 1974 دیده می‌شود.

رابطه کاملاً واضح و مثبت است. هرچه سال ساخت جدیدتر باشد، هم میانگین قیمت و هم بیشترین قیمت‌های ممکن افزایش پیدا می‌کند. به وضوح از سال 2015 به بعد، نقاطی با قیمت بالای 200000 دلار ظاهر می‌شوند که در سال‌های قدیمی‌تر اصلاً دیده نمی‌شدند. همچنین پراکندگی قیمت در سال‌های اخیر بیشتر شده، یعنی در سال‌های جدید طیف وسیع‌تری از خودروهای ارزان تا بسیار گران‌قیمت وجود دارد.

نمودار سوم

Relationship between Mileage and Price

تصویر نمودار را در این قسمت قرار دهید.



تحلیل نمودار

- آیا افزایش کارکرد باعث کاهش قیمت شده است؟
- آیا داده پرت مشاهده می‌شود؟

پاسخ:

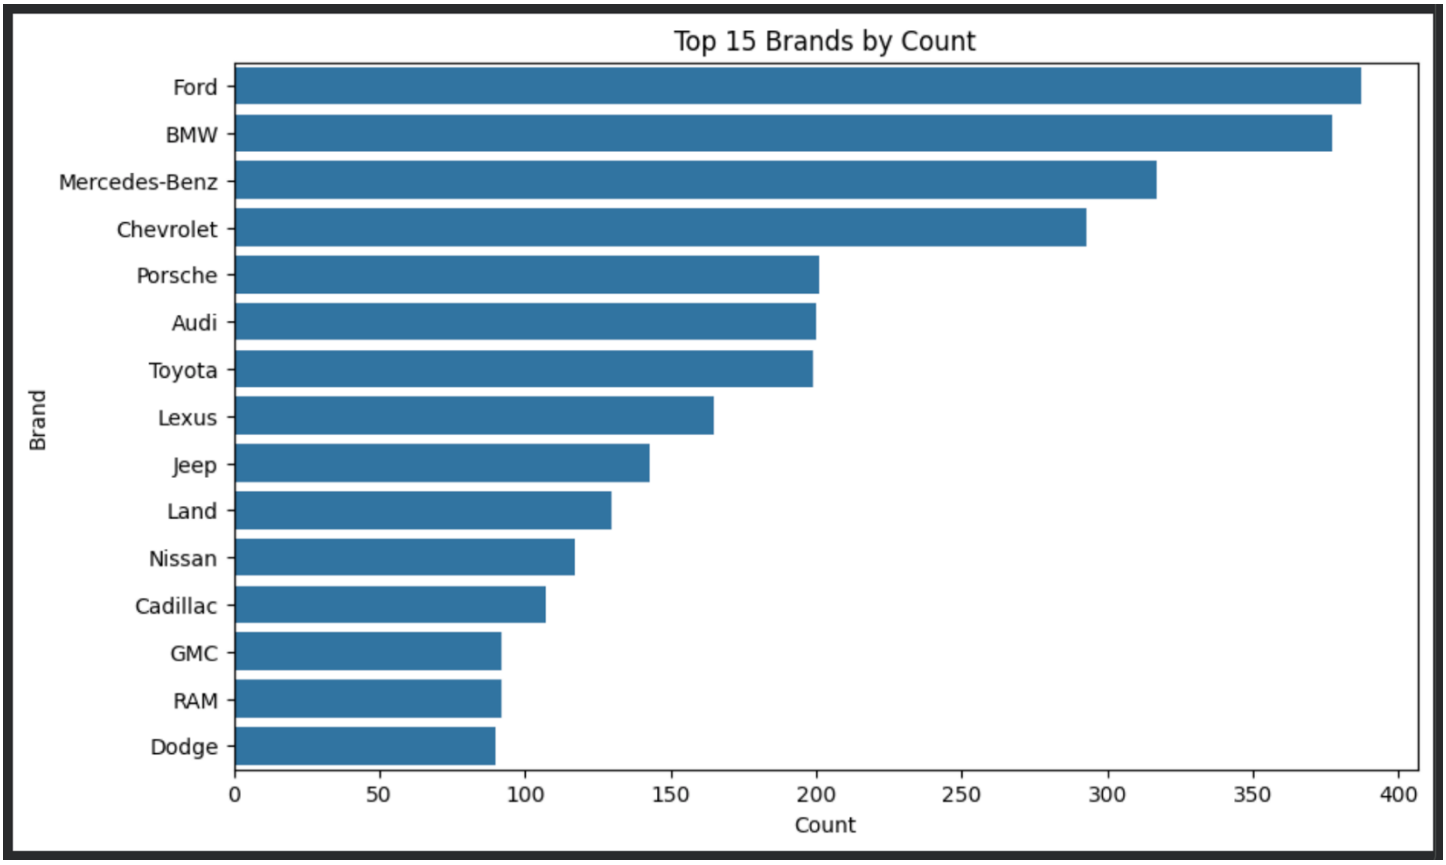
بله، افزایش کارکرد باعث کاهش واضح قیمت شده است. رابطه معکوس بسیار مشخصی بین این دو متغیر دیده می‌شود. بیشترین تراکم قیمت‌های بالا، یعنی بالای 150000 دلار، دقیقاً در نزدیکی محور صفر کارکرد قرار دارد و با افزایش کارکرد، هم چگالی نقاط و هم بیشینه قیمت به سرعت کاهش می‌یابد. شکل کلی نمودار شبیه یک منحنی نزولی نمایی است.

بله، داده پرت هم مشاهده می‌شود. دو نوع در این نمودار قابل توجه است. اول، چند خودرو با کارکرد بسیار بالا، در حدود 350000 تا 405000 مایل، که در سمت راست نمودار پخش شده‌اند. دوم، یک نقطه با کارکرد نسبتاً پایین، در حدود 120000 مایل، ولی قیمت غیرمنتظره بالا، حدود 105000 دلار، که از الگوی کلی جدا افتاده است.

نمودار چهارم

Number of Cars by Brand

تصویر نمودار را در این قسمت قرار دهید.



تحلیل نمودار

- کدام برند بیشترین تعداد خودرو را دارد؟
- آیا توزیع برندها متعادل است؟

پاسخ:

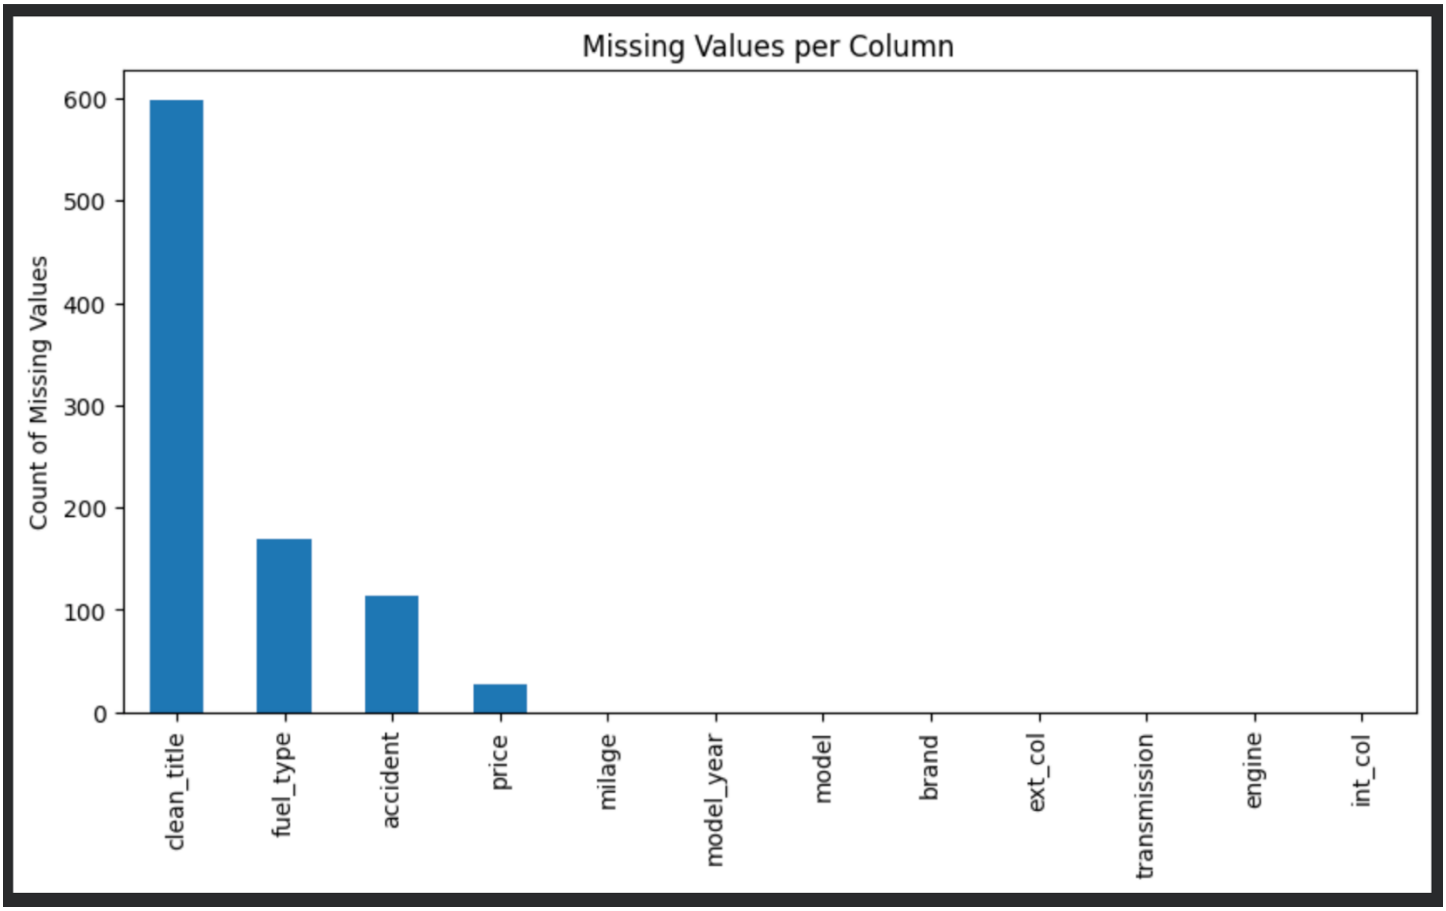
برند فورد با حدود 387 خودرو، بیشترین تعداد را در بین پانزده برند برتر دارد. پس از آن بی‌ام‌و با حدود 377 خودرو و مرسدس بنز با حدود 317 خودرو در رتبه‌های بعدی قرار دارند.

خیر، توزیع کاملاً نامتعادل است. چهار برند نخست، یعنی فورد، بی‌ام‌و، مرسدس بنز و شورولت، با اختلاف محسوسی از باقی برندها جلوتر هستند و هرکدام بیش از 290 خودرو دارند. در مقابل، برندهای انتهای این جدول مانند داج و رم تنها حدود 90 خودرو دارند. با توجه به اینکه در کل دیتاست 57 برند مختلف وجود دارد، بسیاری از این برندها حتی کمتر از 10 رکورد دارند که نشان‌دهنده تمرکز شدید داده روی چند برند پرتیراژ است. همچنین در این نمودار می‌توان مشاهده کرد که نام برند «Land» به طور ناقص ثبت شده و احتمالاً باید « Land Rover» باشد، که نشان‌دهنده نیاز به تمیزکاری داده پیش از مدل‌سازی است.

نمودار پنجم

Missing Values

تصویر نمودار را در این قسمت قرار دهید.



تحلیل نمودار

- کدام ستون بیشترین مقدار گمشده را دارد؟
- آیا قبل از ساخت مدل باید داده‌ها پاک‌سازی شوند؟ توضیح دهید.

پاسخ:

، با حدود 598 مقدار گمشده، به مراتب بیشترین تعداد را دارد. پس از آن ستون نوع سوخت با clean_title ستون وضعیت سند، یعنی حدود 170 مورد و ستون سابقه تصادف با حدود 114 مورد در رتبه‌های بعدی قرار دارند. ستون قیمت نیز حدود 28 مقدار گمشده دارد. .سایر ستون‌ها، از جمله برند، مدل، سال ساخت و کارکرد، هیچ مقدار گمشده‌ای ندارند

بله، قطعاً باید داده‌ها پاک‌سازی شوند. با توجه به تعداد بالای مقادیر گمشده در ستون clean_title، نزدیک به 15 درصد کل داده، این ستون باید یا حذف شود یا با روش مناسبی پر شود. همچنین ردیف‌هایی که مقدار ستون price را ندارند، چون price متغیر هدف پروژه است، باید پیش از آموزش مدل حذف شوند. ستون‌های fuel_type و accident نیز نیاز به پر کردن مقادیر گمشده دارند، مثلاً با جایگزینی با پرتکرارترین مقدار هر ستون.

پایان گزارش

با تکمیل این گزارش، شما باید نشان دهید که ساختار دیتاست را به خوبی درک کرده‌اید، تحلیل اولیه را انجام داده‌اید و آمادگی ورود به مرحله Data Cleaning و آماده‌سازی داده برای ساخت مدل را دارید.