Used Car Price Prediction

Phase 2 Report Template

Data Cleaning & Data Preprocessing

---

1. Introduction

در چند خط توضیح دهید هدف فاز دوم پروژه چیست و چرا پاک‌سازی داده‌ها قبل از ساخت مدل Machine Learning اهمیت دارد.

پاسخ:

هدف فاز دوم پروژه، پاک‌سازی و آماده‌سازی دیتاست برای ورود به مرحله مدل‌سازی است. در این فاز رکوردهای تکراری حذف شدند، مقادیر گمشده مدیریت شدند، ستون engine بررسی شد، داده‌های پرت شناسایی شدند و سازگاری منطقی مقادیر عددی بررسی شد.
پاک‌سازی داده پیش از ساخت مدل اهمیت زیادی دارد، چون کیفیت داده ورودی مستقیماً روی دقت و قابل‌اعتماد بودن مدل یادگیری ماشین تأثیر می‌گذارد؛ داده‌ی ناقص، تکراری یا ناسازگار می‌تواند باعث یادگیری اشتباه مدل و نتایج غیرقابل‌اعتماد شود.

---

2. Data Quality Assessment

2-1.تعداد سطرها و ستون‌های دیتاست را بنویسید.

پاسخ:

Rows:

4023

Columns:

12

2-2.آیا داده‌های تکراری در دیتاست وجود دارد؟

پاسخ:

بله، 14 رکورد کاملاً تکراری در دیتاست وجود داشت که در تمام 12 ستون با یک رکورد دیگر یکسان بودند.

2-3.کدام ستون‌ها دارای مقدار گمشده (Missing Value) هستند؟

پاسخ:

چهار ستون دارای مقدار گمشده بودند: clean_title با 598 مورد (بیشترین)، fuel_type با 170 مورد، accident با 114 مورد و price با 28 مورد.

.4-2مهم‌ترین مشکلات دیتاست را بنویسید.

پاسخ:

مهم‌ترین مشکلات این دیتاست عبارتند از وجود 14 رکورد تکراری، مقادیر گمشده قابل‌توجه در چهار ستون به‌خصوص clean_title (حدود 15 درصد)، و ناهمگونی ساختاری در ستون engine که ترکیبی از چند اطلاعات مختلف در یک رشته متنی است.

---

3. Duplicate Data

آیا داده‌های تکراری حذف شدند؟

پاسخ:

بله، تمام رکوردهای تکراری با استفاده از drop_duplicates() حذف شدند.

تعداد داده‌های تکراری قبل از حذف:

14

تعداد داده‌های تکراری بعد از حذف:

0

---

4. Missing Values

برای هر ستون دارای مقدار گمشده، تصمیم خود را بنویسید.

ستون: قیمت

اقدام انجام شده: حذف ردیف‌های دارای مقدار گمشده

دلیل: این ستون متغیر هدف پروژه است و امکان جایگزینی معتبر برای آن وجود ندارد

ستون: نوع سوخت

اقدام انجام شده: پر کردن با پرتکرارترین مقدار

دلیل: درصد مقادیر گمشده این ستون کم بود، حدود چهار درصد

ستون: سابقه تصادف

اقدام انجام شده: پر کردن با پرتکرارترین مقدار

دلیل: درصد مقادیر گمشده این ستون کم بود، حدود سه درصد

ستون: وضعیت سند

اقدام انجام شده: جایگزینی با مقدار نامشخص

دلیل: درصد مقادیر گمشده بالا بود، حدود پانزده درصد، و پر کردن با مقدار غالب باعث سوگیری می‌شد

چرا سطرهای دارای مقدار گمشده در ستون price حذف شدند؟

پاسخ:

چون price متغیر هدف (target) این پروژه است. برخلاف ویژگی‌های ورودی که می‌توان مقدار گمشده آن‌ها را با روش‌های آماری جایگزین کرد، نمی‌توان قیمت واقعی یک خودرو را حدس زد یا ساخت؛ هر جایگزینی باعث می‌شد مدل روی داده ساختگی آموزش ببیند و نتایج غیرقابل‌اعتماد تولید کند.

چرا برای سایر ستون‌ها مقدار Unknown جایگزین شد؟

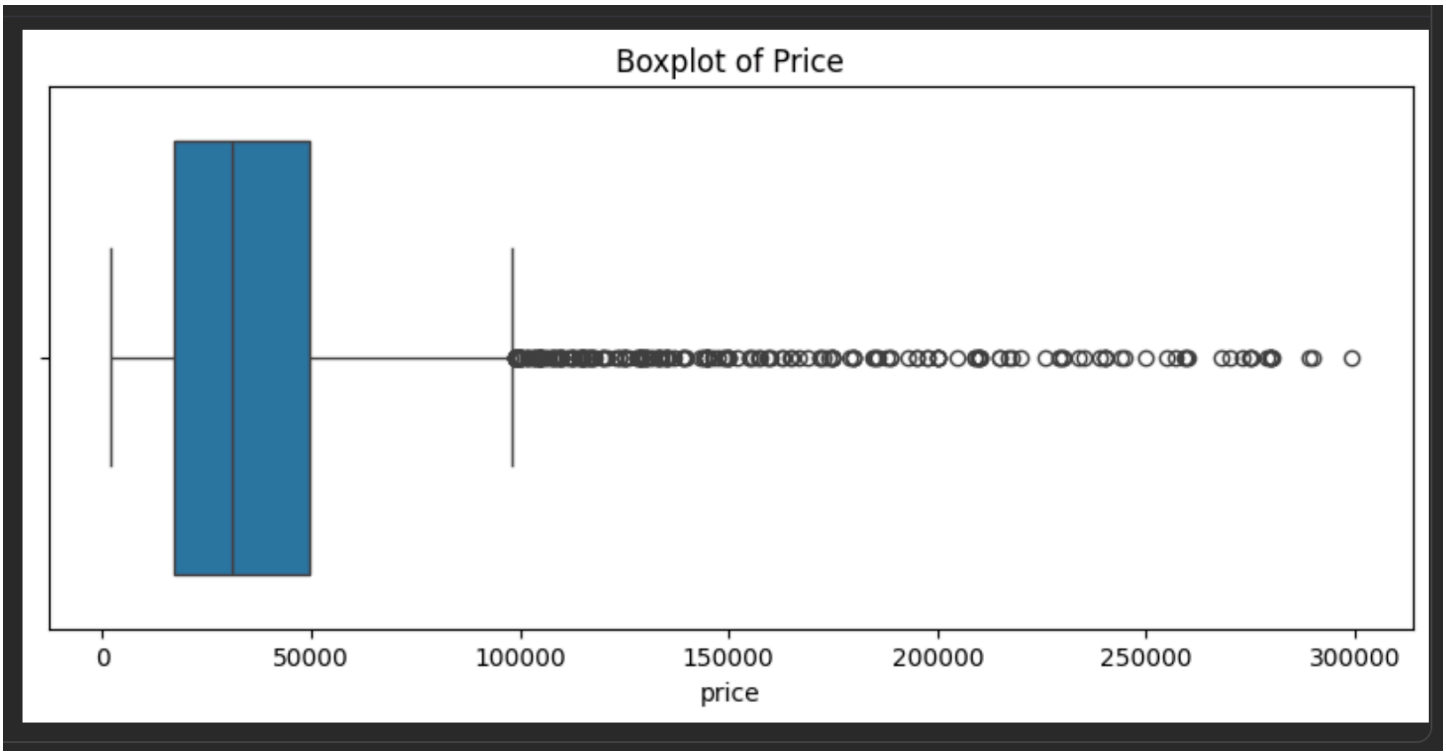
پاسخ:

برای clean_title که درصد گمشدگی بالایی داشت، به‌جای پر کردن با مقدار غالب که می‌توانست باعث سوگیری شود (فرض نادرست اینکه همه خودروها سند تمیز دارند)، مقدار Unknown به‌عنوان یک دسته جدید و معنادار در نظر گرفته شد تا این عدم قطعیت به‌صورت صادقانه در داده باقی بماند.

---

5. Outlier Detection

تصویر Boxplot ستون Price را قرار دهید.



تحلیل نمودار

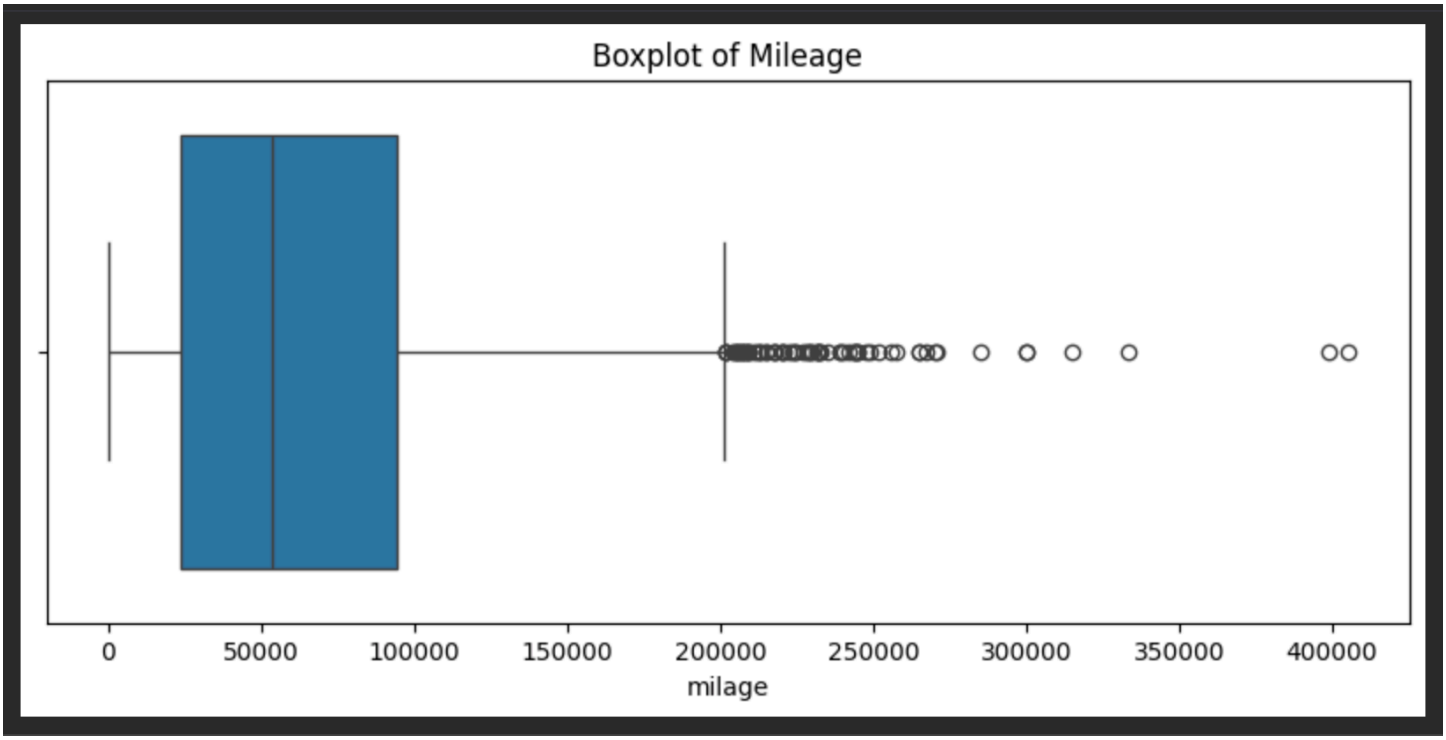
- **آیا داده پرت مشاهده می‌شود؟**
- **آیا حذف آن‌ها ضروری است؟ چرا؟**

پاسخ:

بله، در ستون قیمت داده پرت مشاهده می‌شود. محدوده نرمال تا حدود صد هزار دلار است و پس از آن تعداد زیادی نقطه تا سیصد هزار دلار به عنوان داده پرت دیده می‌شود

حذف آن‌ها ضروری نیست، چون این داده‌های پرت اکثراً نشان‌دهنده خودروهای لوکس واقعی هستند، نه خطای ثبت داده. حذف آن‌ها باعث از دست رفتن اطلاعات ارزشمند درباره بخش گران‌قیمت بازار می‌شود.

تصویر Boxplot ستون Milage را قرار دهید.



تحلیل نمودار

- **آیا داده پرت مشاهده می‌شود؟**
- **آیا حذف آن‌ها ضروری است؟ چرا؟**

پاسخ:

بله، در ستون کارکرد نیز داده پرت مشاهده می‌شود. محدوده نرمال تا حدود دویست هزار مایل است و پس از آن نقاط پراکنده‌ای تا چهارصد هزار مایل به عنوان داده پرت ظاهر می‌شوند.

حذف آن‌ها ضروری نیست، چون این مقادیر نشان‌دهنده خودروهای قدیمی با کارکرد واقعی بالا هستند، نه خطا. حذف آن‌ها اطلاعات مفیدی را از دیتاست حذف می‌کند.

---

6. Data Type Validation

آیا نوع داده ستون‌ها مناسب است؟

پاسخ:

بله، نوع داده اکثر ستون‌ها مناسب است. ستون‌های model_year و milage به‌درستی int64 و ستون price به‌درستی float64 هستند. ستون‌های متنی نیز به‌درستی از نوع object هستند.

آیا ستونی وجود دارد که نیاز به تغییر نوع داده داشته باشد؟

پاسخ:

بله، ستون engine. این ستون در حال حاضر object است که برای نگهداری متن خام مشکلی ندارد، اما چون ترکیبی از چند اطلاعات عددی (قدرت موتور، حجم موتور) و دسته‌ای (نوع سیلندر) است، در فازهای بعدی پس از استخراج ویژگی باید به چند ستون با نوع داده مناسب تبدیل شود.

---

7. Data Consistency

آیا قیمت منفی در دیتاست وجود دارد؟

پاسخ:

خیر، هیچ مقدار منفی در ستون price یافت نشد.

آیا کارکرد (Milage) منفی وجود دارد؟

پاسخ:

خیر، هیچ مقدار منفی در ستون milage یافت نشد.

آیا سال ساخت غیرمنطقی مشاهده شد؟

پاسخ:

خیر، هیچ سال ساخت غیرمنطقی (کمتر از 1900 یا بیشتر از 2026) مشاهده نشد.

در صورت مشاهده داده غیرمنطقی، چه تصمیمی برای آن گرفتید؟

پاسخ:

از آنجا که هیچ مورد غیرمنطقی در هیچ‌کدام از سه بررسی یافت نشد، نیازی به اقدام اصلاحی در این بخش نبود.

---

8. Saving Clean Dataset

آیا دیتاست نهایی با نام cars_clean.csv ذخیره شد؟

پاسخ:

بله

---

9. Final Conclusion

مهم‌ترین تغییراتی که روی دیتاست انجام دادید را بنویسید.

پاسخ:

مهم‌ترین تغییرات شامل حذف چهارده رکورد تکراری، مدیریت مقادیر گمشده در چهار ستون شامل حذف ردیف‌های بدون قیمت، پر کردن ستون نوع سوخت و سابقه تصادف با مقدار غالب، و جایگزینی ستون وضعیت سند با مقدار نامشخص، بررسی ساختار ستون موتور، شناسایی داده‌های پرت در قیمت و کارکرد، و تأیید سازگاری منطقی مقادیر عددی بود. در نهایت دیتاست پاک‌شده با شکل نهایی سه هزار و نهصد و هشتاد و یک سطر و دوازده ستون ذخیره شد.

به نظر شما کیفیت دیتاست نسبت به قبل بهتر شده است؟ چرا؟

پاسخ:

بله، به طور قابل توجهی بهتر شده است. دیتاست دیگر فاقد رکورد تکراری است، مقادیر گمشده آن مدیریت شده و دیگر خالی نیستند، و ساختار ستون‌ها بررسی و تأیید شده است. این کار باعث می‌شود مدل در فاز بعدی روی داده‌ای تمیزتر و قابل‌اعتمادتر آموزش ببیند.

آیا دیتاست اکنون برای ورود به مرحله Feature Engineering آماده است؟ دلیل خود را بنویسید.

:پاسخ

بله، دیتاست اکنون تا حد زیادی آماده است، چون مشکلات اصلی کیفیت داده مانند تکرار و مقادیر گمشده برطرف شده‌اند. تنها نکته باقی‌مانده این است که ستون موتور هنوز به صورت متن خام است و در فاز بعدی باید از آن ویژگی‌های عددی و دسته‌ای جداگانه، مانند قدرت موتور و حجم موتور، استخراج شود.