Used Car Price Prediction

Phase 3 Report

Feature Engineering & Feature Encoding

---

1. Introduction

در چند خط توضیح دهید Feature Engineering چیست و چرا قبل از آموزش مدل‌های Machine Learning اهمیت دارد.

پاسخ:

مهندسی ویژگی یعنی ساختن ویژگی‌های جدید و مفید از داده‌های موجود و تبدیل داده‌های متنی به عدد. این کار لازم است چون مدل‌های یادگیری ماشین فقط با عدد کار می‌کنند و نمی‌توانند ستون‌های متنی یا ستونی که چند اطلاعات مختلف را در خود دارد مستقیم پردازش کنند. شکل و کیفیت ویژگی‌ها مستقیم روی دقت مدل اثر می‌گذارد، برای همین این مرحله پیش از آموزش مدل انجام می‌شود.

---

2. Initial Feature Analysis

2-1. ستون‌های عددی دیتاست را بنویسید.

پاسخ:

model_year

milage

price

2-2. ستون‌های متنی دیتاست را بنویسید.

پاسخ:

brand

model

fuel_type

engine

transmission

ext_col

int_col

accident

clean_title

.2-3ستون Target پروژه چیست؟

پاسخ:

price

.2-4کدام ستون‌ها مستقیماً قابل استفاده در مدل نبودند؟ دلیل خود را بنویسید.

پاسخ:

هر نه ستون متنی دیتاست مستقیم قابل استفاده در مدل نبودند، چون مدل‌های یادگیری ماشین فقط مقدار عددی می‌پذیرند. ستون‌های موتور و گیربکس وضعیت ویژه‌تری داشتند، چون علاوه بر متنی بودن، چند اطلاعات مختلف را در یک رشته نگه می‌داشتند و ساختار ناهمگون داشتند. این دو ستون نیاز به استخراج ویژگی داشتند، نه فقط تبدیل ساده به عدد.

---

3. Engine Feature Extraction

در این بخش ویژگی‌های جدید از ستون Engine استخراج شدند.

.3-1چه ویژگی‌هایی از ستون Engine استخراج کردید؟

پاسخ:

✅Horsepowe

✅Engine Size

✅ Engine Type

□سایر موارد:

ندارد

3-2.تصویر خروجی چند سطر اول دیتاست پس از استخراج ویژگی‌ها را قرار دهید.

	engine	horsepower	engine_size	engine_type
0	300.0HP 3.7L V6 Cylinder Engine Flex Fuel Capa...	300.0	3.7	V6
1	3.8L V6 24V GDI DOHC	NaN	3.8	V6
2	3.5 Liter DOHC	NaN	3.5	Other
3	354.0HP 3.5L V6 Cylinder Engine Gas/Electric H...	354.0	3.5	V6
4	2.0L I4 16V GDI DOHC Turbo	NaN	2.0	I4
5	2.4 Liter	NaN	2.4	Other
6	292.0HP 2.0L 4 Cylinder Engine Gasoline Fuel	292.0	2.0	4 Cylinder
7	282.0HP 4.4L 8 Cylinder Engine Gasoline Fuel	282.0	4.4	8 Cylinder
8	311.0HP 3.5L V6 Cylinder Engine Gasoline Fuel	311.0	3.5	V6
9	534.0HP Electric Motor Electric Fuel System	534.0	NaN	Electric

---

3-3.آیا در ویژگی‌های جدید مقدار گمشده (NaN) مشاهده شد؟

پاسخ:

بله. ستون قدرت موتور هفتصد و هشتاد و نه مقدار گمشده و ستون حجم موتور دویست و شانزده مقدار گمشده دارد. ستون نوع موتور مقدار گمشده ندارد، چون مواردی که الگویی در آن‌ها پیدا نشد در یک دسته جداگانه قرار گرفتند.

3-4.علت وجود این مقادیر گمشده چیست؟

پاسخ:

این مقادیر گمشده خطای استخراج نیستند و دلیلشان نبودن اطلاعات در متن اصلی است. در بسیاری از ردیف‌ها قدرت موتور اصلاً در متن ذکر نشده بود. حجم موتور به لیتر هم برای موتورهای الکتریکی معنا ندارد و در بعضی متن‌های کوتاه که فقط نوع سیلندر را دارند ذکر نشده بود.

---

4. Transmission Standardization

4-1.چرا ستون Transmission نیاز به استانداردسازی داشت؟

پاسخ:

مقادیر این ستون یکدست نبودند و بیش از شصت شکل مختلف داشتند، مثل اتوماتیک ساده، اتوماتیک با تعداد سرعت‌های متفاوت، حالت‌های اختصاری و چند مقدار نامعتبر. ستونی با این تعداد مقدار منحصربه‌فرد برای مدل قابل استفاده نیست و باید در چند گروه استاندارد خلاصه می‌شد.

4-2.گروه‌های نهایی تعریف‌شده را بنویسید.

پاسخ:

✅**Automatic**

✅**Manual**

✅**CVT**

✅**Dual Shift**

✅**Other**

4-3.تعداد خودروهای هر گروه را گزارش کنید.

گروه	تعداد
Automatic	3087
Manual	370
CVT	100
Dual Shift	399
Other	25

4-4.آیا استانداردسازی باعث کاهش تعداد دسته‌ها شد؟

پاسخ:

بله. تعداد مقادیر مختلف این ستون از بیش از شصت مقدار به فقط پنج دسته کاهش پیدا کرد.

---

5. Encoding

5-1.برای هر ستون چه روشی انتخاب کردید؟

ستون	روشEncoding
brand	Label Encoding
fuel_type	One Hot Encoding
accident	Label Encoding
clean_title	Label Encoding
engine_type	Label Encoding
transmission_clean	One Hot Encoding

5-2.دلیل انتخاب روش Encoding را توضیح دهید.

پاسخ:

معیار اصلی انتخاب، تعداد دسته‌های هر ستون بود. برای ستون‌هایی با دسته کم، یعنی نوع سوخت با هفت دسته و گیربکس استانداردشده با پنج دسته، روش وان‌هات انتخاب شد، چون تعداد ستون‌های جدید منطقی می‌ماند و بین دسته‌ها ترتیب ساختگی ایجاد نمی‌شود. برای برند با پنجاه و شش دسته و نوع موتور با هفده دسته، روش لیبل انتخاب شد تا تعداد ستون‌ها بیش از حد زیاد نشود. برای سابقه تصادف و وضعیت سند که فقط دو دسته دارند هم لیبل انتخاب شد، چون یک ستون صفر و یک کافی است. نقطه ضعف این انتخاب این است که لیبل روی برند و نوع موتور یک ترتیب عددی ساختگی ایجاد می‌کند که برای مدل‌های خطی می‌تواند گمراه‌کننده باشد.

5-3.تعداد ستون‌های دیتاست قبل و بعد از Encoding را بنویسید.

مرحله	تعداد ستون
قبل ازEncoding	16
بعد ازEncoding	30

عدد سی پیش از حذف ستون‌های اضافی است. پس از حذف آن‌ها تعداد نهایی ستون‌ها بیست و یک شد.

---

6. Removing Unnecessary Features

6-1. چه ستون‌هایی حذف شدند؟

پاسخ:

Engine, transmission, Brand, accident, clean_title, engine_type, model, ext_col, int_col

---

6-2. چرا این ستون‌ها حذف شدند؟

پاسخ:

ستون‌های موتور و گیربکس حذف شدند چون اطلاعات مفیدشان قبلاً در ستون‌های قدرت موتور، حجم موتور، نوع موتور و گیربکس استانداردشده ذخیره شده بود. نسخه‌های متنی برند، سابقه تصادف، وضعیت سند و نوع موتور حذف شدند چون نسخه عددی آن‌ها ساخته شده بود. ستون‌های مدل، رنگ بدنه و رنگ داخل به ترتیب هزار و هشتصد و هشتاد و سه، سیصد و دوازده و صد و پنجاه دسته دارند و کدگذاری آن‌ها یا ستون‌های بسیار زیادی می‌ساخت یا ترتیب عددی بی‌معنا ایجاد می‌کرد. چون تعداد ردیف‌ها حدود چهار هزار است، بیشتر مدل‌ها فقط یک یا دو بار تکرار شده‌اند و مدل نمی‌تواند از آن‌ها یاد بگیرد. باید ذکر شود که با حذف ستون موتور، جزئیاتی مانند توربو بودن از دست رفت.

---

7. Dataset Validation

7-1. ابعاد نهایی دیتاست را بنویسید.

Rows:

3981

Columns:

21

7-2. آیا مقدار گمشده در دیتاست نهایی وجود دارد؟

پاسخ:

خیر. مقادیر گمشده قدرت موتور و حجم موتور با میانه همان ستون پر شد و تعداد کل مقادیر گمشده در دیتاست نهایی صفر است.

7-3. آیا هنوز ستون متنی در دیتاست وجود دارد؟

پاسخ:

خیر، هیچ ستون متنی در دیتاست نهایی باقی نمانده است.

7-4.آیا دیتاست برای آموزش مدل آماده است؟

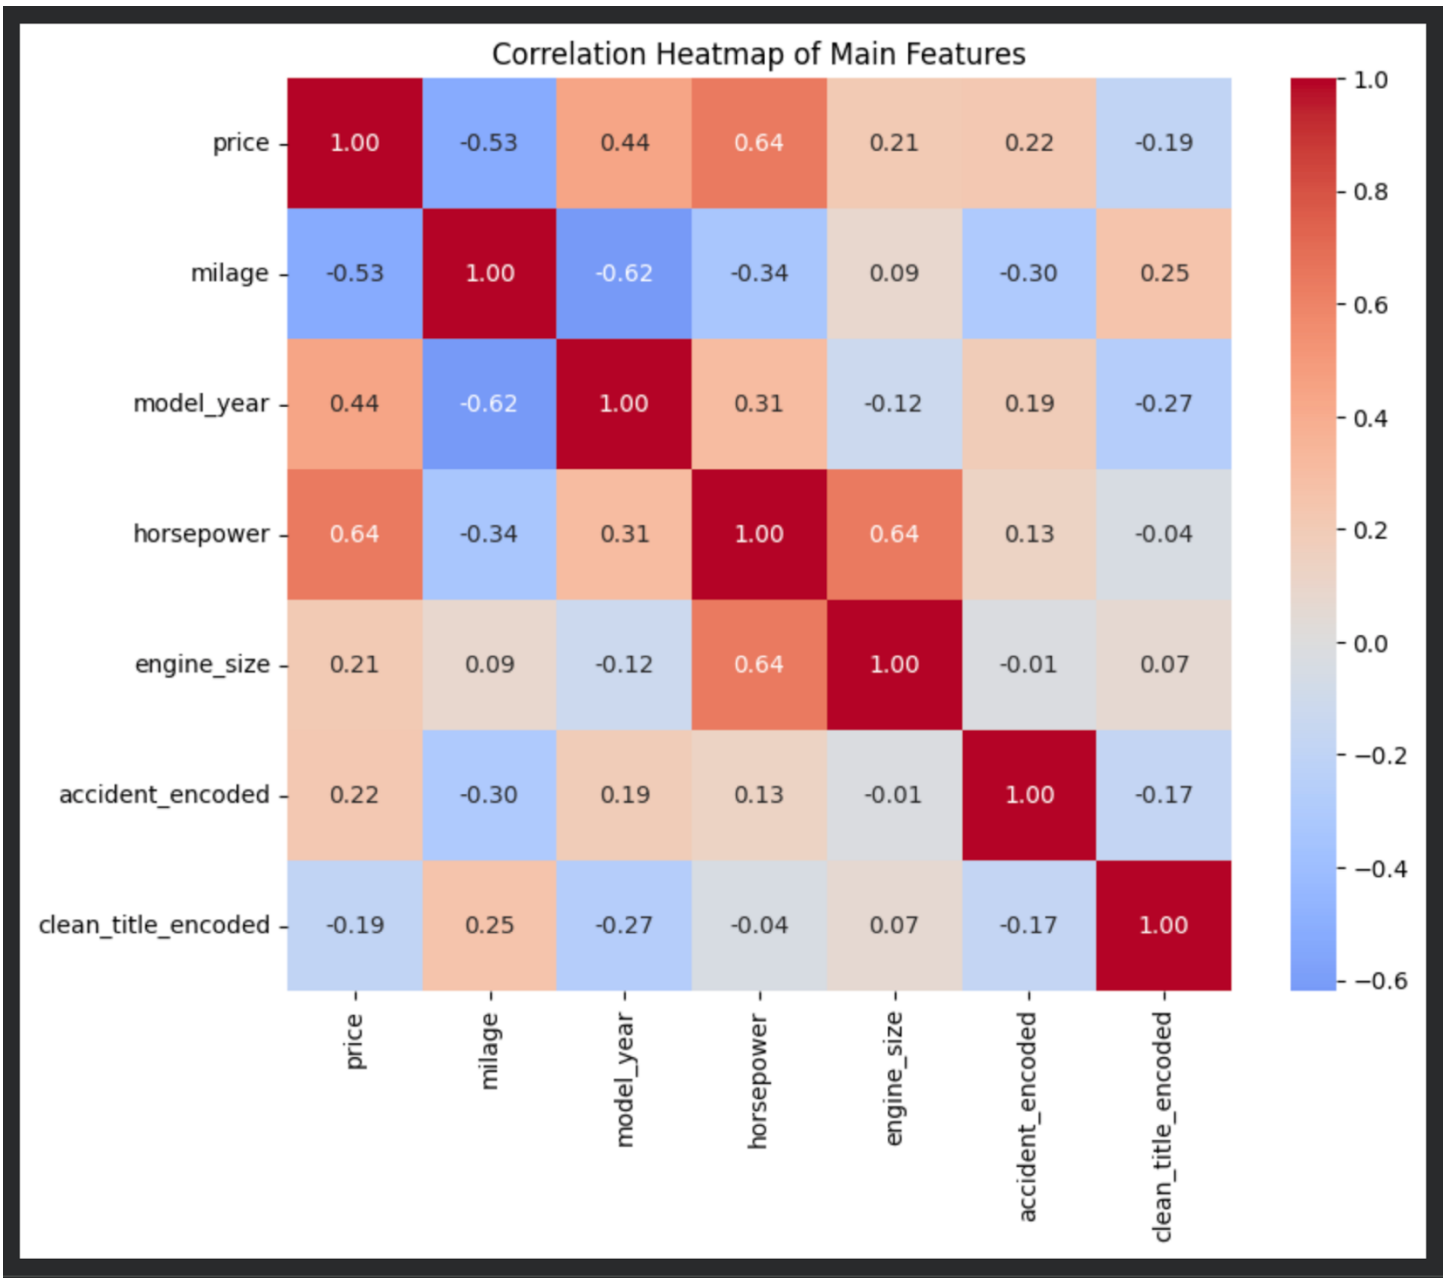
پاسخ:

بله، از نظر ساختاری آماده است: همه ستون‌ها عددی هستند، مقدار گمشده ندارند و ستون‌های وان‌هات به صفر و یک تبدیل شده‌اند. چند محدودیت وجود دارد. پر کردن حدود بیست درصد از قدرت موتور با میانه روشی ساده است. لیبل روی برند و نوع موتور ترتیب ساختگی ایجاد می‌کند که برای مدل‌های خطی اهمیت دارد. مقیاس‌دهی ویژگی‌ها هم هنوز انجام نشده و برای بعضی مدل‌ها لازم است. این موارد باید در فاز مدل‌سازی مدنظر باشند.

---

8. Correlation Analysis

8-1.تصویر Heatmap را در این بخش قرار دهید.



8-2. کدام ویژگی بیشترین ارتباط را با Price دارد؟

پاسخ:

قدرت موتور با ضریب همبستگی حدود ۰,۶۴ بیشترین ارتباط را با قیمت دارد و رابطه‌اش مثبت است. پس از آن کارکرد با ضریب منفی ۰,۵۳ و سال ساخت با ضریب ۰,۴۴ قرار دارند.

8-3. آیا بین دو ویژگی دیگر نیز همبستگی قابل توجهی مشاهده شد؟

پاسخ:

بله، دو مورد دیده شد. کارکرد و سال ساخت با ضریب منفی ۰,۶۲ همبستگی دارند، چون خودروهای قدیمی‌تر مدت بیشتری کار کرده‌اند. قدرت موتور و حجم موتور هم با ضریب ۰,۶۴ همبستگی دارند، چون موتورهای بزرگ‌تر معمولاً قدرت بیشتری دارند.

8-4. تحلیل نتایج Heatmap

حداقل ۳ خط تحلیل بنویسید.

پاسخ:

قدرت موتور قوی‌ترین رابطه مثبت را با قیمت دارد، یعنی خودروهای قوی‌تر معمولاً گران‌ترند. کارکرد رابطه معکوس دارد و سال ساخت رابطه مثبت، که با تحلیل نموداری فاز اول همخوانی دارد. حجم موتور، سابقه تصادف و وضعیت سند ارتباط ضعیف‌تری با قیمت دارند و هیچ ویژگی‌ای همبستگی بالای ۰,۸ ندارد، پس قیمت به ترکیبی از ویژگی‌ها وابسته است. همبستگی بالای کارکرد با سال ساخت و قدرت موتور با حجم موتور یعنی هر جفت تا حدی اطلاعات تکراری دارند که برای مدل‌های خطی می‌تواند مشکل ایجاد کند. چند محدودیت هم باید ذکر شود. ضریب همبستگی فقط رابطه خطی را می‌سنجد، در حالی که رابطه کارکرد و قیمت شبیه منحنی نزولی است. همبستگی هم علیت نیست. ضرایب قدرت موتور و حجم موتور فقط روی ردیف‌هایی حساب شده که این مقدار را داشتند، چون تحلیل پیش از پر کردن مقادیر گمشده انجام شد. وضعیت سند هم با صفر برای نامشخص و یک برای بله کد شده، پس ضریب منفی آن یعنی خودروهای با وضعیت سند نامشخص گران‌ترند و نباید آن را اثر منفی سند تمیز دانست.

---

9. Final Dataset

آیا فایل cars_features.csv با موفقیت ذخیره شد؟

✅ بله

□ خیر

نام فایل نهایی

پاسخ:

cars_features.csv

---

10. Final Conclusion

مهم‌ترینFeature هایی که در این فاز ایجاد شدند را نام ببرید.

پاسخ:

قدرت موتور، حجم موتور، نوع موتور و گیربکس استانداردشده از ستون‌های موتور و گیربکس ساخته شدند. ستون‌های عددی کدگذاری‌شده برای برند، سابقه تصادف، وضعیت سند و نوع موتور و ستون‌های وان‌هات نوع سوخت و گیربکس هم ایجاد شدند.

مهم‌ترین تغییری که روی دیتاست انجام شد چه بود؟

پاسخ:

مهم‌ترین تغییر تبدیل دیتاستی با نه ستون متنی به دیتاستی کاملاً عددی با بیست و یک ستون بود. اطلاعات پنهان در ستون‌های موتور و گیربکس بیرون کشیده شد، ستون‌های دسته‌ای کدگذاری شدند و ستون‌هایی که قابل کدگذاری مفید نبودند حذف شدند. مقادیر گمشده هم پر شد تا دیتاست برای آموزش مدل آماده شود.

به نظر شما کدام ویژگی بیشترین تأثیر را در پیش‌بینی قیمت خودرو خواهد داشت؟ دلیل خود را بنویسید.

پاسخ:

به نظر من قدرت موتور بیشترین تأثیر را خواهد داشت، چون در ماتریس همبستگی با ضریب حدود ۰,۶۴ بیشترین ارتباط را با قیمت داشت. کارکرد و سال ساخت هم احتمالاً مهم هستند. البته این نظر فقط بر پایه همبستگی خطی است و نتیجه نهایی را باید مدل در فاز بعدی نشان بدهد.