Phase 4 Report

Used Car Price Prediction

آموزش و ارزیابی اولین مدلMachine Learning

1.معرفی مدل

نام مدل:

Linear Regression

هدف استفاده از این مدل چیست؟

هدف، پیش‌بینی قیمت خودروهای دست دوم از روی ویژگی‌هایی مانند سال ساخت، کارکرد، قدرت موتور، برند و نوع سوخت است. رگرسیون خطی ساده‌ترین مدل پیش‌بینی عددی است و به عنوان اولین مدل پایه انتخاب شد تا فرایند استاندارد آموزش و ارزیابی مدل یاد گرفته شود و عملکرد آن مبنایی برای مقایسه با مدل‌های بعدی باشد.

2.آماده‌سازی داده‌ها

چه ستون‌هایی قبل از آموزش مدل حذف شدند؟ چرا؟

ستون‌های نام مدل خودرو، رنگ بدنه و رنگ داخل که در فاز سوم حذف شده بودند، در این فاز هم با بررسی تأیید شد که در دیتاست وجود ندارند. این سه ستون به ترتیب هزار و هشتصد و هشتاد و سه، سیصد و دوازده و صد و پنجاه دسته دارند. وان‌هات برای آن‌ها بیش از دو هزار و سیصد ستون جدید می‌ساخت و لیبل ترتیب عددی بی‌معنا ایجاد می‌کرد.
ستون قیمت هم از ویژگی‌ها جدا شد، چون ستون هدف است و اگر در ورودی می‌ماند، مدل پاسخ را از قبل داشت. باید ذکر شود که حذف نام مدل خودرو ممکن است کمی از دقت بکاهد.

آیا داده‌ها دارای مقادیر گمشده بودند؟

□بله

✅خیر

اگر بله، توضیح دهید چگونه این مقادیر مدیریت شدند.

در دیتاست این فاز هیچ مقدار گمشده‌ای وجود نداشت و بررسی دوباره روی ویژگی‌ها هم صفر مقدار گمشده نشان داد. مقادیر گمشده پیش‌تر در فازهای دوم و سوم مدیریت شده بودند.

چرا داده‌ها قبل از آموزش مدل Scale شدند؟

ویژگی‌های پیوسته مقیاس‌های بسیار متفاوتی دارند، مثلاً کارکرد تا چند صد هزار می‌رسد و حجم موتور کمتر از ده است. استانداردسازی آن‌ها را هم‌مقیاس می‌کند تا ضرایب مدل قابل مقایسه باشند و هیچ ویژگی‌ای فقط به دلیل بزرگ بودن واحدش مهم‌تر دیده نشود. برای رگرسیون خطی ساده، این کار پیش‌بینی‌ها را تغییر نمی‌دهد، ولی برای بسیاری از مدل‌های بعدی ضروری است. اسکیلر فقط روی داده‌های آموزش یاد گرفت و همان روی داده‌های آزمون اعمال شد تا اطلاعات آزمون به آموزش نشت نکند.

3.تقسیم داده‌ها

نسبت تقسیم داده‌ها را بنویسید.

Train :

۸۰ درصد

Test :

۲۰ درصد

چرا داده‌ها به دو بخش Train و Test تقسیم می‌شوند؟

مدل باید روی خودروهایی ارزیابی شود که هنگام آموزش ندیده است. اگر مدل با همه داده‌ها آموزش ببیند و با همان داده‌ها آزمون شود، ممکن است فقط داده‌ها را حفظ کرده باشد و عملکرد واقعی آن مشخص نشود. برای تکرارپذیر بودن نتایج، تقسیم با مقدار ثابت برای تصادفی‌سازی انجام شد.

4.آموزش مدل

مدل مورد استفاده:

Linear Regression

به نظر شما ضرایب (Coefficients) مدل چه مفهومی دارند؟

ضرایب نشان می‌دهند مدل برای هر ویژگی چه وزنی یاد گرفته است. قیمت پیش‌بینی‌شده مقدار ثابت مدل به علاوه مجموع وزن‌دار ویژگی‌هاست. ضریب مثبت یعنی با بیشتر شدن آن ویژگی قیمت پیش‌بینی‌شده بالا می‌رود و ضریب منفی یعنی پایین می‌آید. برای چهار ویژگی پیوسته استانداردشده، ضریب برابر تغییر قیمت به ازای یک انحراف معیار افزایش آن ویژگی است. در مدل ما قدرت موتور و سال ساخت ضریب مثبت و کارکرد ضریب منفی داشتند، که با تحلیل فازهای قبل همخوانی دارد. ضرایب ستون‌های وان‌هات و لیبل را نمی‌توان تک‌تک تفسیر کرد، چون در گروه‌های وان‌هات فقط تفاوت ضرایب معنا دارد و کد لیبل فقط ترتیب الفبایی است. ضرایب بیانگر ارتباط در این داده هستند و علیت را نشان نمی‌دهند.

.5ارزیابی مدل

نتایج معیارهای ارزیابی

معیار	مقدار
MAE	16550.57
MSE	842451300
RMSE	29025.01
R^2 Score	0.44

مقدار R^2 نشان‌دهنده چیست؟

ضریب تعیین نشان می‌دهد مدل چه بخشی از تغییرات قیمت‌ها را توضیح می‌دهد. مقدار یک یعنی پیش‌بینی کامل و مقدار صفر یعنی مدل بهتر از این نیست که همیشه میانگین قیمت را حدس بزند. مقدار حدود صفر ممیز چهل و چهار یعنی مدل حدود چهل و چهار درصد از تغییرات قیمت را توضیح می‌دهد و بقیه توضیح داده نشده است.

آیا مقدار R^2 به‌دست‌آمده را مناسب می‌دانید؟ چرا؟

برای استفاده واقعی خیر. مقدار صفر ممیز چهل و چهار نشان می‌دهد مدل چیزهایی یاد گرفته و از حدس زدن میانگین بهتر است، اما بیش از نیمی از تغییرات قیمت توضیح داده نشده است. میانگین خطای مطلق حدود چهل و یک درصد قیمت متوسط است. به عنوان اولین مدل پایه قابل قبول است، چون هدف این فاز یادگیری فرایند بود و جهت رابطه ویژگی‌ها با قیمت درست یاد گرفته شده است.

کدام معیار برای شما قابل فهم‌تر بود؟ دلیل خود را بنویسید.

میانگین خطای مطلق، چون هم‌واحد با قیمت است و مستقیم می‌گوید مدل به طور متوسط چند دلار اشتباه می‌کند. مقدار حدود شانزده هزار و پانصد و پنجاه دلار را می‌شود با میانگین قیمت مقایسه کرد. میانگین مربع خطا در واحد دلار به توان دو است و مستقیم قابل خواندن نیست و ریشه آن برای برگرداندن به دلار لازم است.

6.تحلیل پیش‌بینی‌ها

پس از مقایسه مقادیر واقعی و پیش‌بینی‌شده، عملکرد مدل را توضیح دهید.

عملکرد مدل در ده نمونه اول یکنواخت نیست. برای خودرویی با قیمت واقعی حدود چهل و سه هزار دلار، اختلاف کمتر از هزار دلار بود. در مقابل، برای خودرویی با قیمت واقعی صد و سی و چهار هزار دلار، مدل حدود هفتاد و شش هزار دلار پیش‌بینی کرد و حدود پنجاه و هشت هزار دلار خطا داشت. خطاهای بزرگ‌تر بیشتر در خودروهای گران‌قیمت دیده می‌شود و یکی از دلایل احتمالی آن این است که مدل از اطلاعات برند استفاده چندانی نکرده است. برای یک خودرو هم قیمت پیش‌بینی‌شده نزدیک به صفر شد، چون رگرسیون خطی حد پایینی برای خروجی ندارد. ده نمونه برای قضاوت درباره کل مدل کافی نیست و ارزیابی دقیق‌تر با معیارهای خطا روی همه هفتصد و نود و هفت خودروی آزمون انجام شد.

7.تحلیل نمودار Actual vs Predicted

نمودار رسم‌شده را بررسی کنید.

آیا نقاط به خط مرجع نزدیک هستند؟

☐بله

✅خیر

این موضوع چه چیزی درباره عملکرد مدل نشان می‌دهد؟

در بازه خودروهای ارزان و متوسط، تا حدود هفتاد هزار دلار که بیشتر داده‌ها در آن هستند، نقطه‌ها نسبتاً نزدیک خط مرجع قرار دارند و مدل عملکرد قابل قبولی دارد. با بالا رفتن قیمت واقعی، نقطه‌ها از خط فاصله می‌گیرند و زیر آن می‌مانند. برای خودروهای بالای صد هزار دلار، قیمت پیش‌بینی‌شده تقریباً بین پنجاه تا نود هزار دلار باقی می‌ماند، حتی وقتی قیمت واقعی به حدود دویست و هشتاد هزار دلار می‌رسد. یعنی مدل قیمت خودروهای گران‌قیمت را به طور سیستماتیک کمتر از واقعیت پیش‌بینی می‌کند. در پایین نمودار هم چند خودرو ارزان‌قیمت پیش‌بینی منفی دارند. شکل کلی ابر نقطه‌ها منحنی است، که نشان می‌دهد رابطه ویژگی‌ها با قیمت کاملاً خطی نیست و یک مدل خطی نمی‌تواند همه آن را بگیرد.

.8ذخیره مدل

مدل با چه فرمتی ذخیره شد؟

فرمت pkl، با کتابخانه joblib

چرا ذخیره مدل در پروژه‌های Machine Learning اهمیت دارد؟

مدل آموزش‌دیده در حافظه نگهداری می‌شود و با بستن برنامه از بین می‌رود. ذخیره مدل باعث می‌شود بدون آموزش دوباره، که ممکن است زمان‌بر باشد، بتوان آن را بعداً بارگذاری کرد، روی خودروهای جدید پیش‌بینی انجام داد، نتایج را تکرار کرد و مدل را با دیگران به اشتراک گذاشت یا در یک برنامه واقعی به کار برد. اگر پیش‌پردازش مانند اسکیلر هم ذخیره نشود، مدل برای داده جدید قابل استفاده کامل نیست.

.9جمع‌بندی

به نظر شما مهم‌ترین نکته‌ای که در این فاز یاد گرفتید چه بود؟

مهم‌ترین نکته این بود که ارزیابی مدل باید روی داده‌ای انجام شود که مدل ندیده است و اینکه اسکیلر فقط باید از داده‌های آموزش یاد بگیرد، وگرنه نشت داده باعث نتیجه خوش‌بینانه می‌شود. همچنین یاد گرفتم که یک معیار تنها کافی نیست: ضریب تعیین و خطای مطلق و نمودار پیش‌بینی هر کدام بخشی از عملکرد را نشان می‌دهند و مدلی که از حدس میانگین بهتر است، لزوماً برای استفاده واقعی کافی نیست.

پیشنهادی برای بهبود مدل

اگر بخواهید در آینده دقت مدل را افزایش دهید، چه ایده‌هایی دارید؟

چند ایده برای افزایش دقت وجود دارد. اول، استفاده از لگاریتم قیمت به عنوان هدف، چون قیمت چوله است و رابطه کارکرد با قیمت نزولی نمایی است، و این کار می‌تواند پیش‌بینی منفی را هم از بین ببرد. دوم، استفاده بهتر از برند، مثلاً وان‌هات برای برندهای پرتکرار و گروه سایر برای بقیه، چون برند در مدل فعلی تقریباً بی‌اثر شد. سوم، حفظ بخشی از اطلاعات نام مدل خودرو که حذف شده بود. چهارم، جایگزین کردن پر کردن قدرت موتور با میانه با روش دقیق‌تر. پنجم، امتحان مدل‌های غیرخطی مانند جنگل تصادفی و مقایسه آن‌ها با رگرسیون خطی، و استفاده از اعتبارسنجی متقابل برای ارزیابی پایدارتر. این‌ها ایده هستند و تأثیرشان باید با آزمایش سنجیده شود.