Phase 5 Report

Used Car Price Prediction

مقایسه مدل‌های یادگیری ماشین

---

1. معرفی

در این فاز سه مدل مختلف یادگیری ماشین برای پیش‌بینی قیمت خودرو آموزش داده شدند. هدف این مرحله، مقایسه عملکرد مدل‌ها و انتخاب بهترین مدل برای ادامه پروژه است.

---

2. مدل‌های استفاده شده

نام سه مدل استفاده شده را بنویسید.

Linear Regression

Decision Tree Regressor

Random Forest Regressor

تفاوت اصلی این مدل‌ها از نظر عملکرد چیست؟

رگرسیون خطی ساده‌ترین مدل است و فقط رابطه‌های خطی را می‌گیرد، پس برای رابطه‌های غیرخطی مانند رابطه کارکرد و قیمت ضعیف است و به داده‌های پرت هم حساس است. درخت تصمیم می‌تواند رابطه‌های غیرخطی را بگیرد، ولی اگر محدود نشود داده‌های آموزش را حفظ می‌کند و روی داده‌های جدید ضعیف می‌شود. جنگل تصادفی از میانگین‌گیری صد درخت ساخته شده است، پس هم رابطه‌های غیرخطی را می‌گیرد و هم دقیق‌تر و پایدارتر از یک درخت تنهاست. بهای این دقت، کندتر و سنگین‌تر بودن آن و سخت‌تر بودن تفسیر آن است.

.3 نتایج ارزیابی مدل‌ها

.جدول نتایج را تکمیل کنید

Linear Regression R^2 Score: 0.444 RMSE: 29025 MAE: 16551

Decision Tree R^2 Score: 0.478 RMSE: 28116 MAE: 12724

Random Forest R^2 Score: 0.747 RMSE: 19580 MAE: 9489

.4 تحلیل نتایج

MAE کدام مدل کمترین مقدار را دارد؟

.جنگل تصادفی، با حدود نه هزار و چهارصد و هشتاد و نه دلار

R^2 کدام مدل بیشترین مقدار را دارد؟

.جنگل تصادفی، با ضریب تعیین صفر ممیز هفتصد و چهل و هفت

.بهترین مدل این پروژه کدام است؟ دلیل خود را بنویسید

جنگل تصادفی بهترین مدل است، چون کمترین خطا، یعنی کمترین میانگین خطای مطلق و کمترین ریشه میانگین مربع خطا، و بیشترین ضریب تعیین را دارد. میانگین خطای مطلق آن حدود بیست و چهار درصد قیمت متوسط خودروهای آزمون است، در حالی که برای رگرسیون خطی حدود چهل و یک درصد است. درخت تصمیم روی داده‌های آموزش ضریب تعیین یک گرفت ولی روی داده‌های آزمون فقط صفر ممیز چهارصد و هفتاد و هشت، یعنی داده‌ها را حفظ کرده است. جنگل تصادفی با .میانگین‌گیری از چندین درخت این مشکل را بسیار کمتر دارد

.آیا نتایج مدل‌ها با یکدیگر اختلاف قابل توجهی دارند؟ توضیح دهید

بله، به‌ویژه بین رگرسیون خطی و جنگل تصادفی. میانگین خطای مطلق حدود چهل و سه درصد کمتر شد و ضریب تعیین از صفر ممیز چهارصد و چهل و چهار به صفر ممیز هفتصد و چهل و هفت رسید. اختلاف رگرسیون خطی و درخت تصمیم کوچک‌تر است، به‌ویژه در ضریب تعیین. چون این نتایج از .یک تقسیم آموزش و آزمون به دست آمده‌اند، اختلاف‌های کوچک را نباید بیش از حد تفسیر کرد

---

5. تحلیل Feature Importance

.تشخیص داده است را بنویسید Random Forest سه ویژگی مهمی که مدل

Milage

Engine_size

Horsepower

چرا این ویژگی‌ها می‌توانند بر قیمت خودرو تأثیرگذار باشند؟

کارکرد: هرچه کارکرد بیشتر باشد، خودرو فرسوده‌تر است و قیمت کمتر می‌شود. این افت قیمت .غیرخطی و در ابتدا تند است و جنگل تصادفی می‌تواند آن را بگیرد

حجم موتور: هرچه حجم موتور بیشتر باشد، قیمت معمولاً بیشتر است، چون موتورهای بزرگ‌تر در .خودروهای بزرگ‌تر، لوکس و اسپرت استفاده می‌شوند

قدرت موتور: هرچه قدرت موتور بیشتر باشد، قیمت معمولاً بیشتر است، چون قدرت بالا نشان‌دهنده رده .عملکردی و لوکس بودن خودرو است

---

6. Feature Scaling

نیاز داشت؟ Feature Scaling کدام مدل به

.رگرسیون خطی. این مدل روی داده‌های استانداردشده آموزش دید تا ضرایب آن قابل مقایسه باشند

نیاز ندارند؟ Feature Scaling معمولاً به Random Forest و Decision Tree چرا **مدل‌های**

چون این مدل‌ها داده را با آستانه‌گذاری روی یک ویژگی در هر مرحله تقسیم می‌کنند، پس فقط ترتیب .مقادیر هر ویژگی اهمیت دارد و بزرگ یا کوچک بودن مقیاس آن اثری ندارد

.7 ذخیره مدل

.نام فایل مدل ذخیره شده را بنویسید

best_model.pkl

اهمیت دارد؟ Machine Learning چرا ذخیره مدل در **پروژه‌های**

چون مدل آموزش‌دیده فقط در حافظه وجود دارد و با بستن برنامه از بین می‌رود. با ذخیره مدل می‌توان آن را بدون آموزش دوباره بارگذاری کرد و روی خودروهای جدید پیش‌بینی انجام داد، نتایج را تکرار کرد و آن را با دیگران به اشتراک گذاشت یا در یک برنامه واقعی به کار برد

.8 جمع‌بندی

به نظر شما مهم‌ترین نکته‌ای که در این فاز یاد گرفتید چه بود؟

یاد گرفتم برای یک مسئله باید چند مدل را آموزش داد، همه را با معیارهای یکسان روی داده آزمون ارزیابی کرد و بعد بهترین را انتخاب کرد، نه اینکه از اول فقط به یک مدل اکتفا کرد. همچنین دیدم که .نمودار اهمیت ویژگی‌ها کمک می‌کند بفهمیم مدل از کدام ویژگی‌ها بیشتر استفاده کرده است

اگر بخواهید یکی از این مدل‌ها را در یک پروژه واقعی استفاده کنید، کدام مدل را انتخاب می‌کنید؟ دلیل خود را بنویسید

.

جنگل تصادفی را، چون رابطه‌های غیرخطی بین ویژگی‌ها و قیمت را می‌گیرد و در این مقایسه عملکرد بهتری از دو مدل دیگر داشت. با این حال خطای آن هنوز حدود یک‌چهارم قیمت متوسط است، پس برای استفاده واقعی باید دقت آن با روش‌هایی مانند تنظیم پارامترها و کدگذاری بهتر برند بالاتر برده شود.